



UNIVERSITAS INDONESIA

**THIN-CLIENT PIPELINING DARI CONVOLUTIONAL NEURAL
NETWORK UNTUK PENGENALAN BATIK**

THESIS

**MUHAMMAD ARIF NASUTION
1306500580**

**FAKULTAS ILMU KOMPUTER
MAGISTER ILMU KOMPUTER
DEPOK
JUNI 2016**



UNIVERSITAS INDONESIA

**THIN-CLIENT PIPELINING DARI CONVOLUTIONAL NEURAL
NETWORK UNTUK PENGENALAN BATIK**

THESIS

**Diajukan sebagai salah satu syarat untuk memperoleh gelar
Master Ilmu Komputer**

MUHAMMAD ARIF NASUTION

1306500580

**FAKULTAS ILMU KOMPUTER
PROGRAM STUDI MAGISTER ILMU KOMPUTER**

**DEPOK
JUNI 2016**

HALAMAN PERSETUJUAN

Judul : Thin-Client Pipelining dari Convolutional Neural Network untuk
Pengenalannya Batik
Nama : Muhammad Arif Nasution
NPM : 1306500580

Laporan Thesis ini telah diperiksa dan disetujui.

XX XXX XXXX

Mohammad Ivan Fanany

Pembimbing Thesis

HALAMAN PERNYATAAN ORISINALITAS

**Thesis ini adalah hasil karya saya sendiri,
dan semua sumber baik yang dikutip maupun dirujuk
telah saya nyatakan dengan benar.**

Nama : Muhammad Arif Nasution
NPM : 1306500580
Tanda Tangan :

Tanggal : XX XXX XXXX

HALAMAN PENGESAHAN

Thesis ini diajukan oleh :
Nama : Muhammad Arif Nasution
NPM : 1306500580
Program Studi : Magister Ilmu Komputer
Judul Thesis : Thin-Client Pipelining dari Convolutional Neural Network untuk Pengenalan Batik

Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Master Ilmu Komputer pada Program Studi Magister Ilmu Komputer, Fakultas Ilmu Komputer, Universitas Indonesia.

DEWAN PENGUJI

Pembimbing : Mohammad Ivan Fanany ()

Penguji : Prof. XXX ()

Penguji : Prof. XXXX ()

Penguji : Prof. XXXXXX ()

@todo

Jangan lupa mengisi nama para penguji.

Ditetapkan di : Depok

Tanggal : XX XXX XXXX

KATA PENGANTAR

Alhamdulillahirabbil'alamin, segala puji dan syukur kehadiran Tuhan Yang Maha Esa, Allah Subhana Huwataala, karena hanya dengan hidayah dan rahmat-Nya, penulis dapat menyelesaikan pembuatan skripsi ini.

Allahumma sholli 'alaa sayyidina Muhammad, Sholawat serta salam tak henti-hentinya dipanjatkan kepada Rasulullah SAW, atas peranannya di muka bumi dalam memberikan tuntunan kepada seluruh umat manusia, dan sebagai inspirasi atas seluruh manusia sebagai manusia dengan akhlak terbaik.

Penulisan thesis ini ditujukan untuk memenuhi salah satu syarat untuk menyelesaikan pendidikan pada Program Master Ilmu Komputer, Universitas Indonesia. Saya sadar bahwa dalam perjalanan menempuh kegiatan penerimaan dan adaptasi, belajar-mengajar, hingga penulisan skripsi ini, penulis tidak sendirian. Penulis ingin berterima kasih kepada pihak-pihak berikut :

Depok, 20 Juni 2016

Muhammad Arif Nasution

ABSTRAK

Nama : Muhammad Arif Nasution
Program Studi : Magister Ilmu Komputer
Judul : Thin-Client Pipelining dari Convolutional Neural Network
untuk Pengenalan Batik

Kain batik merupakan salah satu warisan kebudayaan Indonesia yang menjadi salah satu warisan dunia menurut UNESCO. Batik memiliki beberapa motif seperti motif kawung, motif parangkusumo, motif truntum, motif tambal, motif pamiluto, motif parang, motif liris maupun motif udan nitik. Selain banyak variasi motif batik, daerah asal batik juga beragam dan memiliki makna yang memiliki keterikatan dengan daerah asal batik tersebut. Dengan beragamnya daerah motif maupun daerah asal batik, akan menjadi sulit untuk mengetahui daerah asal batik tersebut jika tidak didukungnya informasi maupun pengetahuan terkait batik. Dengan menggunakan metode convolution neural network, diharapkan dapat membantu mempelajari variasi motif batik untuk mendeteksi daerah asal batik tersebut. Convolution neural network akan melakukan pembelajaran image dengan memecah gambar menjadi lebih kecil atau kernel dan diproses kedalam 2 layer utama (layer konvolusi dan subsampling) hingga mencapai output layer dan dilakukan evaluasi terhadap data tes. Untuk melakukan komputasi CNN, digunakan library deeplearning4j sehingga hasil pembelajaran CNN bisa disimpan dalam file biner yang bisa digunakan kembali untuk melakukan evaluasi motif batik.

Kata Kunci:

Android, Deep Learning, Convolution Neural Network

ABSTRACT

Name : Muhammad Arif Nasution
Program : Magister Ilmu Komputer
Title : Thin-Client Pipelining dari Convolutional Neural Network untuk Pengenalan Batik

Batik is one of Indonesia traditional fabric which recognized by UNESCO as Masterpiece of Oral and Intangible Heritage of Humanity. Batik has many textures such as kawung, parangkusumo, truntum, tambal, pamiluto, parang liris and udan nitik. Moreover, every province in indonesia has their own texture that represent their culture. The problem of batik classification is appeared caused by variation in texture or province and no useful information and knowledge can support batik recognition. So, CNN is proposed to be used in learning texture for batik recognition. CNN will process input into kernel and processed into common layer called convolution and subsampling and the output layer can be used for batik recognition. For CNN computation, deeplarning4j will be used so learning result can be stored into binary file and can be used to evaluate batik texture for batik recognition.

Keywords:

Android, Deep Learning, Convolution Neural Network

DAFTAR ISI

HALAMAN JUDUL	i
LEMBAR PERSETUJUAN	ii
LEMBAR PERNYATAAN ORISINALITAS	iii
LEMBAR PENGESAHAN	iv
KATA PENGANTAR	v
ABSTRAK	vi
Daftar Isi	viii
Daftar Gambar	ix
Daftar Tabel	x
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Permasalahan	2
1.2.1 Definisi Permasalahan	2
1.2.2 Batasan Permasalahan	2
1.3 Tujuan	3
1.4 Metodologi Penelitian	3
1.5 Sistematika Penulisan	3
2 LANDASAN TEORI	5
2.1 Penelitian Sebelumnya	5
2.2 <i>Feedforward Neural Network</i>	8
2.3 Convolution Neural Network (CNN)	10
2.3.1 Convolutional Layer	12
2.3.2 Subsampling Layer	13
2.3.3 <i>Fully Connected Layer</i>	14
2.4 <i>Backpropagation</i>	14
2.5 Algoritma Optimasi	15

2.5.1	<i>Stochastic Gradient Descent (SGD)</i>	16
2.5.2	<i>Nesterov's Accelerated Gradient (Nesterov)</i>	16
2.6	Fungsi Galat	16
2.7	Deeplearning4j	17
2.8	Web Service	17
2.9	Batik	18
3	PERANCANGAN	20
3.1	Teknik Pengumpulan Data	20
3.2	Data	20
3.3	Rancangan Penelitian	20
3.4	Pelatihan Model CNN	22
	Daftar Referensi	24

DAFTAR GAMBAR

2.1	Mind map penelitian terdahulu terkait CNN	5
2.2	Contoh <i>feedforward neural network</i>	8
2.3	Interpretasi geometris pada peran <i>hidden layer</i>	9
2.4	<i>Sparse Connectivity</i>	11
2.5	<i>Shared weights</i> untuk <i>filter</i> yang sama	11
2.6	Ilustrasi <i>layer</i> pada <i>convolutional neural network</i>	12
2.7	Ilustrasi <i>max pooling</i>	13
2.8	Contoh arsitektur <i>convolutional neural network</i>	14
2.9	Mind map penelitian terdahulu terkait CNN	17
2.10	Contoh kain dari berbagai daerah di indonesia	18
3.1	Arsitektur CNN	23
3.2	Arsitektur Server untuk CNN	23

DAFTAR TABEL

2.1	Matriks literatur penelitian terdahulu yang berhubungan dengan penelitian Convolution Neural Network	7
3.1	Project plan penelitian pengenalan batik dengan android	21
3.2	Timeline penelitian pengenalan batik dengan android	22

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Pada pembelajaran mesin, CNN adalah jenis feed-forward jaringan syaraf tiruan pola konektifitas diinspirasi dari organisasi animal visual cortex, dimana neuron individu diatur untuk melakukan respon terhadap area yang overlap untuk melakukan pengolahan visual. CNN terinspirasi dari proses biologi dan merupakan variasi dari MLP yang didesain untuk meminimilasi sumber daya dalam melakukan proses komputasi. CNN sudah banyak digunakan pada variasi aplikasi, beberapa diantaranya pengenalan image atau video, recommender system dan NLP.

Batik merupakan kain bergambar yang memiliki gaya, warna dan tekstur dimana proses pembuatannya dilakukan secara manual maupun menggunakan mesin dan merupakan salah satu kain tradisional yang dimiliki oleh negara indonesia. Batik sudah ditetapkan sebagai Warisan Kemanusiaan untuk Budaya Lisan dan Nonbendawi oleh UNESCO sejak 2 Oktober 2009. Dengan keberagaman suku dan budaya di Indonesia, menyebabkan Indonesia memiliki variasi motif batik yang sangat beraneka ragam dan memiliki makna simbolis berdasarkan daerah asal batik tersebut. Batik memiliki beberapa motif seperti motif kawung, motif parangkusumo, motif truntum, motif tambal, motif pamiluto, motif parang, motif liris maupun motif udan nitik yang menjadi contoh begitu beragamnya variasi motif batik yang ada di Indonesia.

Indonesia merupakan Negara yang termasuk kedalam 10 negara dengan penduduk terbanyak dengan luas wilayah 1.904.569 km² dengan 255.993.674 jiwa. Dengan banyaknya penduduk Indonesia tersebut, juga dibarengi dengan banyaknya pengguna internet di Indonesia yang mencapai 53,236,719 dengan penterasi mencapai 20.4% berdasarkan data <http://www.internetlvestats.com/>. Berdasarkan data <http://www.statista.com/>, pada tahun 2015, pengguna internet di Indonesia via mobilephone mencapai 47.9% dan diprediksi akan meningkat hingga 54.1%.

Penelitian ini bertujuan untuk memanfaatkan convolution neural network untuk membangun model deteksi daerah asal batik yang memiliki akurasi yang lebih baik. Selain itu, dengan semakin meningkatnya teknologi internet dan penggunaan smart phone pada masyarakat, diharapkan proses deteksi batik dengan memanfaatkan smart phone dapat digunakan oleh masyarakat umum dan membantu

pengenalan salah satu budaya Indonesia yang lebih baik dan diharapkan bisa membantu meningkatkan daya tarik wisatawan lokal maupun asing yang bisa berimbas peningkatan devisa negara.

1.2 Permasalahan

Pada bagian ini akan dijelaskan mengenai definisi permasalahan yang Penulis hadapi dan ingin diselesaikan serta asumsi dan batasan yang digunakan dalam menyelesaikannya.

1.2.1 Definisi Permasalahan

Pendahuluan pada butir 1.1 menimbulkan permasalahan-permasalahan yang perlu diselesaikan. Penelitian ini dilakukan untuk menemukan jawaban dari permasalahan-permasalahan tersebut, antara lain sebagai berikut:

1. Bagaimana merancang algoritma CNN untuk melakukan proses learning dan deteksi daerah batik.
2. Bagaimana integrasi hasil pembelajaran CNN agar bisa digunakan oleh web service
3. Bagaimana implementasi client android untuk melakukan komunikasi dengan web service untuk deteksi daerah asal batik

1.2.2 Batasan Permasalahan

Dalam melakukan penelitian ini, terdapat beberapa batasan-batasan yang digunakan. Batasan-batasan tersebut adalah sebagai berikut.

1. Penelitian ini menggunakan data gambar dengan ukuran 70x70.
2. Penelitian ini menggunakan metode CNN untuk membangun model pengenalan motif daerah asal batik.
3. Penelitian ini hanya mendeteksi asal daerah kain dari 5 provinsi Indonesia, Sumatera, Jawa Barat, Jawa Tengah, Jawa Timur, Kalimantan & Sulawesi
4. Penelitian ini menggunakan perangkat lunak JAVA 7 dan library deeplearning4j untuk melakukan proses CNN dan membangun arsitektur web service.

5. Penelitian ini menggunakan perangkat keras dengan spesifikasi sebagai berikut.

- (a) Processor : Intel Core I5-5200U CPU @2.20 GHz.
- (b) RAM : 4.00 GB.
- (c) OS : Windows 7 Profesional

1.3 Tujuan

Berdasarkan permasalahan pada butir 1.2, tujuan-tujuan yang akan dicapai dalam penelitian ini adalah sebagai berikut.

1. Membangun model rancangan CNN untuk melakukan proses pembelajaran motif batik.
2. Membangun layanan web service yang mampu memanfaatkan hasil pembelajaran motif batik dari CNN
3. Membangun aplikasi android yang mampu berinteraksi dengan web service untuk melakukan proses deteksi daerah asal batik

1.4 Metodologi Penelitian

Untuk menjawab masalah yang terdapat pada rumusan masalah dan mencapai tujuan penelitian, penelitian ini dilakukan dengan metode eksperimen dengan langkah-langkah sebagai berikut:

1. Membangun layanan web service untuk membangun model deteksi batik daerah asal batik dengan convolution neural network
2. Membangun aplikasi berbasis android sebagai client yang mampu mengakses layanan web service dan mendapatkan output dari proses CNN

1.5 Sistematika Penulisan

Sistematika penulisan laporan adalah sebagai berikut:

- Bab 1 PENDAHULUAN
Bab 1 berisi pendahuluan yang memberi penjelasan mengenai latar belakang penelitian ini dilakukan, masalah-masalah yang akan diselesaikan melalui

penelitian ini, tujuan-tujuan penelitian yang akan dicapai, batasan penelitian, metode yang akan digunakan dalam penelitian ini, dan struktur penulisan proposal penelitian ini.

- **Bab 2 LANDASAN TEORI**

Bab 2 berisi teori-teori yang berkaitan dalam penelitian yang akan dilaksanakan. Teori-teori tersebut antara lain CNN, deeplearning4j, web service dan batik.

- **Bab 3 PERANCANGAN**


Bab 3 berisi usulan rancangan penelitian yang akan dilaksanakan. Rancangan tersebut terdiri dari langkah-langkah yang akan dilakukan, penjelasan teknis mengenai metode-metode yang akan diterapkan, dan tempat serta waktu penelitian.

BAB 2

LANDASAN TEORI

2.1 Penelitian Sebelumnya

Penelitian-penelitian yang berhubungan dengan penelitian ini adalah penelitian mengenai pendeteksian dan pengenalan objek yang didalamnya menggunakan convolution neural network. Penelitian-penelitian tersebut memiliki keterhubungan seperti yang dapat dilihat pada mind map gambar 2.1.



Gambar 2.1: Mind map penelitian terdahulu terkait CNN

Dalam penelitian terdahulu, yang dilakukan Yizhang, Bailing dan Frans (Yizhang Xia, Bailing Zhang & Frans Coenen, 2015), menjelaskan bahwa CNN dapat dilakukan proses secara multi-task learning. Kasus penelitian yang diambil adalah deteksi wajah dengan teknik oklusi objek-objek yang ada pada wajah, kemudian dilakukan proses learning terhadap tiap objek sehingga terjadi multi-task learning. Perbedaan yang dilakukan penelitian ini adalah banyak penelitian sebelumnya yang menggunakan pendekatan lokalisasi, segmentasi, ekstraksi fitur dan pengenalan objek.

Penelitian lainnya yang dilakukan Earnest Paul dan Krishna (Earnest Paul Ijjina & C Krishna Mohan, 2015) meneliti pengenalan human action menggunakan MOCAP (Motion Capture) dengan Fuzzy Convolution Neural Network. Informasi MOCAP digunakan untuk menghitung variasi pergerakan yang terpisah dan kemudian digabungkan selama proses eksekusi. Fungsi keanggotaan fuzzy digunakan untuk melakukan ekstraksi fitur dengan menggabungkan pose yang berasosiasi dengan

aksi yang dilakukan manusia.

Penelitian lainnya yang dilakukan Lin, Hsu dan Chen (Hsien-I Lin, Ming-Hsiang Hsu & Wei-Kai Chen, 2015) untuk melakukan deteksi terhadap gesture pergerakan dari tangan. Untuk meningkatkan performa, penelitian ini melakukan pemodelan dari kulit dan kalibrasi terhadap posisi dan orientasi dari objek. Untuk menghilangkan noise pada gambar, ditambah pendekatan Gaussian Mixture model (GMM) untuk melakukan training dalam menghadapi permasalahan noise yang diakibatkan cahaya yang berpengaruh terhadap warna kulit. Kalibrasi terhadap posisi dan orientasi objek digunakan untuk proses translasi dan rotasi objek sehingga menjadi pose yang netral. Hasil dari kalibrasi akan digunakan untuk CNN dan menghasilkan akurasi 95.96% untuk pengenalan 7 variasi gesture dari tangan.

Penelitian terkait CNN adalah mengenai transfer learning dengan CNN yang dilakukan oleh Yejun Tang, Liangrui Peng, Qian Xu, Yanwei Wang & Akio Furuhashi. Transfer learning pada CNN digunakan untuk menyelesaikan kasus OCR untuk pengenalan huruf cina. Model transfer learning yang diuji terbagi menjadi 2 arsitektur CNN yaitu T & L dengan prosedur:

1. CNN L dilakukan training untuk melakukan ekstraksi fitur dan batasan klasifikasi.
2. Bobot hasil pembelajaran CNN L disalurkan kepada CNN T untuk diinisialisasi.
3. Layer Fully-Connected dari CNN T dikembangkan dengan beberapa sampel pada domain target untuk menyeimbangkan domain awal dan target, dimana layer konvolusi dan subsampling tetap sama seperti sebelumnya dari CNN L.

Hasil dari penelitian transfer learning memberikan akurasi hingga 88.56% dengan variasi font Kai Ti (kt) and Song Ti (st).

Penelitian-penelitian terdahulu yang telah dijelaskan di atas dapat dituliskan dalam sebuah matriks literatur yang dapat dilihat pada tabel 2.1 sebagai berikut.


Tabel 2.1: Matriks literatur penelitian terdahulu yang berhubungan dengan penelitian Convolution Neural Network

Judul	Face Occlusion Detection Based on Multi-task Convolution Neural Network
Pengarang	Yizhang Xia, Bailing Zhang, Frans Coenen
Tahun	2015
Metode	Pre training, Fine tuning & Multi task predicting
Kontribusi	ConvNets model & A large face occlusion database
Pekerjaan Mendatang	Peningkatan model menggunakan weakly-supervised learning, yang lebih realistis dalam dunia nyata
Judul	Human Action Recognition based on Motion Capture Information using Fuzzy Convolution Neural Networks
Pengarang	Earnest Paul Ijjina, C Krishna Mohan
Tahun	2015
Metode	Motion capture (MOCAP) information using a Fuzzy convolutional neural network
Kontribusi	High classification accuracy can be achieved by extracting features using fuzzy membership functions and MOCAP information of only three human joints
Pekerjaan Mendatang	Extensive experimentation on other MOCAP datasets & Datasets with predicted human joint information like JHMDB, to identify the set of features suitable for action recognition across multiple datasets
Judul	Human Hand Gesture Recognition Using a Convolution Neural Network
Pengarang	Hsien-I Lin, Ming-Hsiang Hsu, and Wei-Kai Chen
Tahun	2014
Metode	Convolution neural network (CNN) method to recognize hand gestures of human task activities from a camera image, Gaussian Mixture model (GMM) to train the skin model which is used to robustly filter out non-skin colors of an image and the calibration of hand position and orientation aims at translating and rotating the hand image to a neutral pose
Kontribusi	
Pekerjaan Mendatang	A high-level semantic analysis will be applied to the current system to enhance the recognition capability for complex human tasks
Judul	A Convolution Neural Network Based Variational Restoration Model
Pengarang	Xinyan Yu, Guohao Lyu, Siwei Luo, Junbo Liu
Tahun	2015
Metode	Convolution neural network for Extracting and expressing the features & Convolution neural network to get classification of features
Kontribusi	Improving Convolution Neural Network with regularization restoration
Pekerjaan Mendatang	Finding effective features and the segmentation of image patch for better restoring image

2.2 Feedforward Neural Network

Di dalam *machine learning*, *artificial neural network* (ANN) adalah model yang terinspirasi oleh *neural network* biologis. *Artificial neural network* dapat melakukan estimasi atau aproksimasi fungsi non-linear dengan nilai *output* yang dapat berupa nilai *real*, diskret, atau vektor. Pada alamnya, neuron menerima sinyal melalui sinaps yang terletak pada dendrit. Neuron akan teraktivasi dan dapat meneruskan sinyal apabila sinyal yang diterima memenuhi batas tertentu. Sinyal tersebut dapat diterima sinaps lain dan dapat mengaktivasi neuron lainnya. Beberapa permasalahan yang dapat diselesaikan dengan ANN diantaranya adalah klasifikasi, kategorisasi, aproksimasi fungsi, dan prediksi.

Feedforward neural network adalah salah satu jenis ANN. *Feedforward neural network* terdiri dari beberapa unit yang dikelompokkan dalam *layer* di mana setiap *layer* yang bersebelahan saling terhubung melalui suatu unit. Pada *feedforward neural network*, koneksi antar *unit* tidak membentuk *cycle* seperti yang ada pada *recurrent neural network*. Kalkulasi *feedforward neural network* dari *input* ke *output* berjalan ke satu arah sesuai dengan strukturnya yang tampak seperti graf berarah. Contoh *feedforward neural network* dengan satu *hidden layer* dapat dilihat pada Gambar 2.2 berikut.




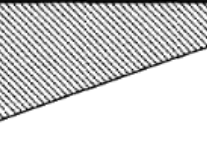
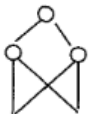
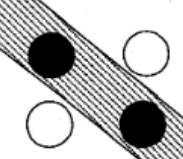

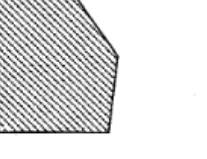
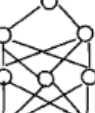
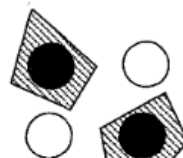




Gambar 2.2: Contoh *feedforward neural network*

Sumber gambar:

<http://technobium.com/stock-market-prediction-using-neuroph-neural-networks/>

Feedforward neural network terdiri dari *input layer*, *output layer*, dan beberapa *hidden layer* apabila dibutuhkan. Jumlah *hidden layer* berperan pada seberapa kompleks batas keputusan yang dapat dibentuk oleh *network* seperti pada Gambar 2.3.

Structure	Description of decision regions	Exclusive-OR problem	Classes with meshed regions	General region shapes
 Single layer	Half plane bounded by hyperplane			
 Two layer	Arbitrary (complexity limited by number of hidden units)			
 Three layer	Arbitrary (complexity limited by number of hidden units)			

Gambar 2.3: Interpretasi geometris pada peran *hidden layer*

Sumber gambar: [?]

Pada *input layer*, jumlah unit atau neuron yang ada sesuai dengan jumlah elemen yang ada pada vektor *input*. Begitu juga dengan *output layer*, jumlah unit yang ada sesuai dengan banyaknya elemen yang diinginkan pada vektor *output*. Berbeda dengan *input layer* dan *output layer*, jumlah unit dalam *hidden layer* sifatnya bebas. Setiap unit menghasilkan suatu *output* dari kombinasi linear beberapa nilai *input* dengan bobotnya masing-masing. Hasil dari kombinasi linear tersebut kemudian diaktivasi dengan fungsi aktivasi. Proses ini dapat dilihat pada Rumus 2.1.

$$y(x) = g \left(\sum_{i=1}^n w_{ij}x_i + w_{0j} \right) \quad (2.1)$$

- x merupakan vektor *input*
- w merupakan vektor bobot
- w_{ij} merupakan bobot yang menghubungkan unit ke- i pada *layer* sebelumnya dan unit ke- j pada *layer* saat itu
- w_{0j} merupakan bobot untuk bias
- g merupakan fungsi aktivasi

Pada Rumus 2.1 vektor *input* pada suatu *layer* bergantung pada *output* di *layer* sebelumnya, kecuali untuk *layer* pertama yaitu *input layer*. Fungsi aktivasi g dapat

berbeda untuk setiap *layer*, tapi pada umumnya sama untuk setiap unit pada *layer* yang sama. Pada penelitian ini fungsi aktivasi yang digunakan adalah *rectified linear unit* (ReLU) yang dapat dilihat pada Rumus 2.2, dan *sigmoid* pada Rumus 2.3.

$$g(x) = \max(0, x) \quad (2.2)$$

$$g(x) = \frac{1}{1 + e^{-x}} \quad (2.3)$$

Pada Rumus 2.1 terdapat w_{0j} yang merupakan bobot untuk bias. Bias bersifat seperti konstanta yang selalu bernilai +1, sehingga pengaruh bias tergantung pada bobotnya.

2.3 Convolution Neural Network (CNN)


CNN merupakan salah satu variasi dari multilayer perceptron (MLP). Keuntungan dari metode CNN, khususnya untuk kasus pengenalan pola dibandingkan pendekatan konvensional adalah kemampuan untuk mengurangi dimensi data, ekstraksi fitur secara sekuensial, dan mengklasifikasi salah satu struktur jaringan. Arsitektur dasar dari model CNN terinspirasi dari visual cortex yang dikenalkan oleh hubel dan wiesel pada tahun 1962.

Pada tahun 1980, neocognitron fukushima membuat pertama kali komputasi menggunakan model CNN, dan kemudian pada tahun 1989, dengan menggunakan model yang ditemukan fukushima, LeCun menemukan performa dari beberapa proses untuk pengenalan pola menggunakan metode error gradient.

Model CNN yang digunakan oleh LeCun merupakan pengembangan dari MLP tradisional yang didasari 3 ide, local receptive field, weight sharing dan spatial subsampling. Ide dasar ini diorganisir kedalam 2 tipe layer, yaitu convolution dan subsampling layer. Seperti yang ditunjukkan gambar 1, digunakan 3 convolution layer dengan kombinasi layer subsampling dan 1 output layer. Layer convolution dan subsampling tersusun kedalam plane atau disebut feature maps.

Convolutional neural network (CNN) adalah salah satu tipe *feedforward neural network* yang terinspirasi dari cara kerja visual korteks. Berdasarkan penelitian, korteks visual terdiri dari banyak sel kompleks. Sel-sel ini disebut *receptive field* dan sensitif terhadap bagian kecil bidang visual. Salah satu sifat yang dimiliki CNN adalah *sparse connectivity*. *Sparse connectivity* memungkinkan suatu *layer* saling terhubung hanya dengan unit-unit terdekat. Dengan kata lain, *input* dari suatu unit merupakan *subset* dari unit pada *layer* sebelumnya. Ilustrasi *sparse connectivity*

dapat dilihat pada Gambar.




Gambar 2.4: *Sparse Connectivity*

Sumber gambar: <http://deeplearning.net/tutorial/lenet.html>

Tumpukan *layer* pada Gambar 2.4 hanya memiliki satu unit pada *layer m + 1*. Hal ini merepresentasikan unit atau bagian-bagian kecil yang ada pada *layer m - 1* bagaikan disaring atau di-filter hingga *layer m + 1* memahami bidang visual secara utuh.

Selain *sparse connectivity*, CNN juga memiliki sifat *shared weights*. Setiap *layer* kecuali *output layer* memiliki *filter* yang fungsinya untuk menyaring bagian kecil dari bidang visual. *Filter* tersebut direplikasi dengan bobot yang sama ke seluruh bidang visual dengan untuk menyaring unit atau bagian-bagian kecil sehingga membentuk *feature map*. Pada Gambar 2.5 berikut, lima unit pada *layer m - 1* disaring dengan *filter* berukuran tiga, sehingga membentuk tiga unit *feature map*. Garis yang berwarna sama menandakan bobot yang sama.



Gambar 2.5: *Shared weights* untuk *filter* yang sama


Sumber gambar: <http://deeplearning.net/tutorial/lenet.html>

Untuk merepresentasikan data atau bidang visual yang kompleks, setiap *layer* pada CNN dapat mempunyai beberapa *feature map* atau *channel*. Rumus untuk menghitung *feature map* ke- k pada *pixel* koordinat (i, j) yang ditentukan oleh bobot W^k dan bias b_k adalah sebagai berikut.

$$y_{ij}^k = g \left((W^k * x)_{ij} + b_k \right) \quad (2.4)$$

Setiap *feature map* pada *layer m - 1* berkontribusi dalam menentukan nilai *feature map k* pada *layer m*. Dengan kata lain, setiap *pixel* yang berada dalam *feature map k* nilainya akan ditentukan oleh seluruh *pixel* yang terhubung, pada *feature map* di *layer m - 1*. Pada ilustrasi Gambar 2.6, *layer m* memiliki dua *feature map* y^0 dan y^1 . *Pixel* (kotak berwarna biru) pada y^0 ditentukan dari 2x2 *pixel* yang terhubung

dengan bobot W_{ij}^{kl} . W_{ij}^{kl} menyatakan bobot yang menghubungkan *pixel* koordinat (i, j) pada *feature map* ke- l di *layer* $m - 1$ ke *pixel* yang terhubung pada *feature map* ke- k di *layer* m .



Gambar 2.6: Ilustrasi *layer* pada *convolutional neural network*
Sumber gambar: <http://deeplearning.net/tutorial/lenet.html>

Convolutional Neural Network biasanya terdiri dari beberapa *filter* atau disebut juga dengan *convolutional layer*, sering kali diikuti dengan *subsampling layer* dan diakhiri dengan *fully connected layers*. Terdapat juga jenis CNN yang tidak diakhiri dengan *fully connected layers* melainkan *convolutional layer* lainnya yang mempertahankan dimensi data dalam bentuk citra 2D. CNN jenis ini disebut dengan *Fully Convolutional Neural Network*.

2.3.1 Convolutional Layer

Pada *layer convolution*, tiap neuron terhubung secara local kepada area yang lebih kecil (*local receptive field*) pada *layer* sebelumnya. Semua neuron yang memiliki *feature maps* yang sama memperoleh data dari input area yang berbeda hingga semua input plan tersaring tetapi saling berbagi bobot (*weight sharing*).

Convolutional layer memiliki tiga *hyperparameter* yang mengatur transformasi *feature map* yang dihasilkan: *depth* D , *stride* S , dan *zero-padding* P . Dalam tahap *feed-forward*, *convolutional layer* berukuran F akan bergeser pada gambar berukuran W , dan menghasilkan *feature map* sebanyak D dengan ukuran W' yang dapat dihitung menggunakan Rumus 2.5 berikut.

$$W' = (W - F + 2P) / S + 1 \quad (2.5)$$


Dalam praktiknya, *zero-padding* sering kali digunakan untuk menyesuaikan ukuran hasil *feature map*. *Zero padding* dengan ukuran $P = (F - 1)/2$ dipastikan menghasilkan *feature map* dengan ukuran yang sama dengan *feature map* sebelumnya apabila *stride* $S = 1$. *Deep learning framework* seperti *theano* menyebut *padding* dengan sifat tersebut sebagai *same padding*. Terdapat juga *full padding* yang menghasilkan *feature map* dengan ukuran $W' = W + F - 1$.

2.3.2 Subsampling Layer

Pada layer subsampling, feature maps didownsampling secara spasial, dimana ukuran map dikurangi berdasarkan 2 faktor. Contohnya, feature map pada layer C3 dengan ukuran 10x10 dilakukan subsampling untuk menyesuaikan feature map dengan ukuran 5x5 pada layer selanjutnya. Layer terakhir adalah F6 yang merupakan proses klasifikasi. Dalam arsitektur *convolutional neural network*, *pooling layer* berfungsi untuk mereduksi ukuran spasial gambar secara bertahap sehingga mengurangi parameter dan komputasi pada *network*. *Pooling layer* menerima *input feature map* berukuran W_1 sebanyak D_1 dan parameter ukuran *pooling* F dan *stride* S . Sama halnya dengan *convolutional layer*, *pooling layer* juga bergeser terhadap input dan menghasilkan *feature map* berjumlah $D_2 = D_1$ dengan ukuran $W_2 = (W_1 - F)/S + 1$. Terdapat beberapa jenis *pooling layer*, dan yang paling sering digunakan adalah:

1. Max Pooling

Dalam *pooling* berukuran F , *Max pooling* akan mengambil hasil aktivasi yang terbesar dalam daerah yang termasuk pada pergeseran saat itu. Ilustrasi ini dapat dilihat pada Gambar 2.7 berikut dengan $F = 2$ dan $S = 2$.



Gambar 2.7: Ilustrasi *max pooling*

Sumber gambar: <http://cs231n.github.io/convolutional-networks>

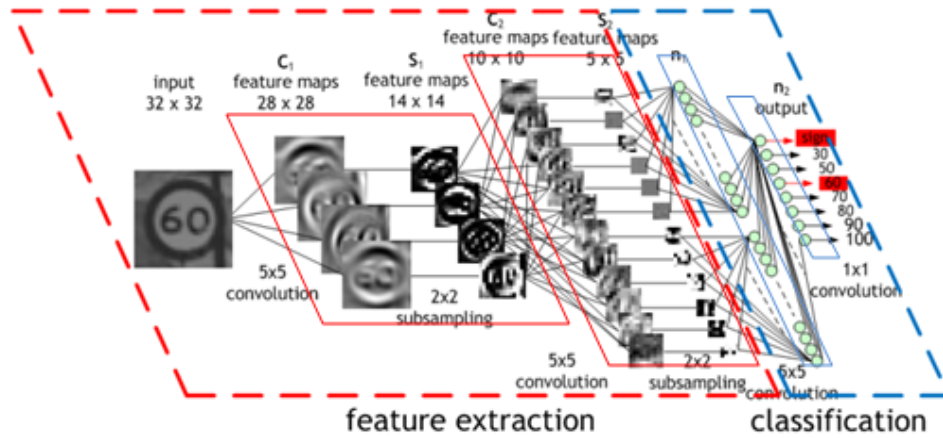
2. Average Pooling

Berbeda dengan *max pooling*, *average pooling* mengambil hasil aktivasi pada

daerah *filter* dan menghitung rata-rata dari seluruh hasil aktivasi dalam daerah tersebut.

2.3.3 Fully Connected Layer

Fully connected layer adalah *feed forward neural network* yang dijelaskan pada subbab 2.2. Biasanya, *fully connected layer* berada pada *layer* akhir pada arsitektur *convolutional neural network* dan bertujuan untuk memproses hasil *feature extraction* yang dilakukan pada *layer* sebelumnya menjadi suatu *output* tertentu. Gambar 2.8 berikut merupakan contoh arsitektur dengan susunan *convolutional layer*, *pooling layer*, dan *fully connected layer*.



Gambar 2.8: Contoh arsitektur *convolutional neural network*
 Sumber gambar: <https://devblogs.nvidia.com>

2.4 Backpropagation

Tujuan dari melatih model *feedforward neural network* adalah membuat model tersebut dapat memprediksi nilai dengan galat seminimal mungkin. *Feedforward neural network* menggunakan metode *backpropagation* untuk melatih nilai bobot-bobot pada *network* tersebut. Untuk melatih suatu bobot, metode ini melakukan *propagation* dari galat pada *output layer* sehingga informasi ini tersebar ke *layer* sebelumnya untuk digunakan dalam mengubah bobot.

Untuk $\delta^{(l+1)}$ sebagai galat pada *layer* $l + 1$ dengan fungsi galat $J(W, b; x, y)$ di mana W, b adalah parameter, dan x, y adalah pasangan *input* dan label, apabila *layer* l dan *layer* $l + 1$ saling terhubung maka galat pada *layer* l adalah sebagai berikut.

$$\begin{aligned}\delta^{(l)} &= ((W^{(l)})^T \delta^{(l+1)}) \cdot f'(z^{(l)}) \\ f'(z^{(l)}) &= a^{(l)} \cdot (1 - a^{(l)})\end{aligned}\tag{2.6}$$

$$\begin{aligned}\Delta_{w^{(l)}} J(W, b; x, y) &= \delta^{(l+1)} (a^{(l)})^T \\ \Delta_{b^{(l)}} J(W, b; x, y) &= \delta^{(l+1)}\end{aligned}\quad (2.7)$$

Pada *convolutional layer* dan *pooling layer*, galat pada *layer l* dihitung dengan fungsi *upsample* $g(x)$ tergantung pada *layer* yang digunakan.

$$\delta_k^{(l)} = \text{upsample}((W_k^{(l)})^T \delta_k^{(l+1)}) \cdot f'(z_k^{(l)}) \quad (2.8)$$

$$g(x) \begin{cases} \frac{\sum_{k=1}^m x_k}{m}, \frac{\delta g}{\delta x} = \frac{1}{m}, & \text{average pooling} \\ \max(x), \frac{\delta g}{\delta x} = \begin{cases} 1, & \text{if } x_i = \max(x) \\ 0, & \text{otherwise} \end{cases} & \text{max pooling} \end{cases}$$

Sumber rumus: <http://www.slideshare.net/kuwajima/cnnbp>

Rumus 2.7 digunakan untuk mengubah bobot pada suatu *layer*. Salah satu cara untuk mengubah bobotnya adalah dengan *stochastic gradient descent* yang menggunakan Rumus 2.9 berikut.

$$\theta = \theta - \alpha \Delta_{\theta} J(\theta; x^{(i)}, y^{(i)}) \quad (2.9)$$

Sumber rumus: <http://ufldl.stanford.edu/tutorial/supervised/ConvolutionalNeuralNetwork>

2.5 Algoritma Optimasi

Algoritma optimasi digunakan untuk permasalahan meminimalisasi *loss*. Untuk *dataset D*, objektif dari optimasi adalah rata-rata *loss* $|D|$ dari seluruh anggota *dataset D*. Dengan $f_W(X^{(i)})$ adalah galat pada data ke $X^{(i)}$, dan $r(W)$ adalah regularisasi dengan bobot λ , maka galat rata-rata dapat dihitung menggunakan Rumus 2.10 berikut .

$$L(W) = \frac{1}{|D|} \sum_i^{|D|} f_W(X^{(i)}) + \lambda r(W) \quad (2.10)$$

Karena $|D|$ pada kenyataannya dapat bernilai sangat besar, dalam praktiknya setiap iterasi menggunakan aproksimasi secara stokastik dengan memilih $N \ll |D|$ sehingga galat rata-rata dihitung dengan Rumus 2.11 berikut .

$$L(W) \approx \frac{1}{N} \sum_i^N f_W(X^{(i)}) + \lambda r(W) \quad (2.11)$$

2.5.1 Stochastic Gradient Descent (SGD)

Stochastic gradient descent mengubah bobot W dengan kombinasi linear dari *gradient* negatif $\Delta L(W)$ dan perbaharuan bobot V_t pada iterasi sebelumnya. Untuk menghitung nilai perbaharuan V_{t+1} dan bobot W_{t+1} pada iterasi $t + 1$ digunakan Rumus 2.12 dan 2.13 berikut .

$$V_{t+1} = \mu V_t - \alpha \Delta L(W_t) \quad (2.12)$$

$$W_{t+1} = W_t + V_{t+1} \quad (2.13)$$

2.5.2 Nesterov's Accelerated Gradient (Nesterov)

Nesterov's accelerated gradient (Nesterov) diusulkan oleh Nesterov sebagai metode optimal untuk optimasi, dengan laju konvergensi mencapai $O(1/t^2)$. Dalam praktiknya, Nesterov dapat menjadi metode yang cukup efektif untuk mengoptimasi arsitektur *deep learning* tertentu, seperti yang didemonstrasikan oleh dalam membuat *autoencoders*. Perubahan bobot dalam algoritma Nesterov menggunakan Rumus berikut .

$$V_{t+1} = \mu V_t - \alpha \Delta L(W_t + \mu V_t) \quad (2.14)$$

$$W_{t+1} = W_t + V_{t+1} \quad (2.15)$$

Perbedaan Nesterov dengan SGD terdapat pada penambahan momentum dalam menghitung *gradient* $\Delta L(W_t + \mu V_t)$. Dalam SGD, perhitungan *gradient* $\Delta L(W_t)$ hanya mengambil bobotnya saja.

2.6 Fungsi Galat

Fungsi galat adalah fungsi yang menghitung galat dari hasil prediksi \hat{y} dengan nilai y yang sebenarnya. Pada penelitian ini, penulis menggunakan dua jenis fungsi galat, yakni *cross-entropy loss* (Rumus 2.16) dan *euclidean loss* (L2) (Rumus 2.17). Dilihat dari fungsinya, *cross entropy* bekerja lebih agresif dalam memperbaiki dibandingkan dengan *euclidean error*.

$$\text{crossentropy}(y, \hat{y}) = -(y * \log(\hat{y}) + (1 - y) * \log(1 - \hat{y})) \quad (2.16)$$

$$euclideanloss(y, \hat{y}) = \frac{1}{2} \|y - \hat{y}\|_2^2 \quad (2.17)$$

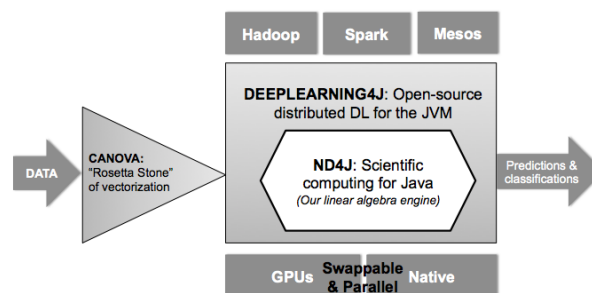
Sumber rumus: <http://caffe.berkeleyvision.org>

2.7 Deeplearning4j

Deeplearning4j adalah library yang berbasis teknologi JAVA yang mampu terintegrasi dengan Hadoop, Spark, DL4J diciptakan untuk digunakan dalam lingkungan bisnis daripada untuk riset.

Deeplearning4j bertujuan memiliki fungsi pembelajaran mesin untuk penggunaan yang siap pakai, sehingga membantu pembuatan prototipe aplikasi yang lebih cepat untuk pengguna selain akademisi atau pelaku riset. Deeplearning4j memiliki lisensi Apache 2 yang dimiliki oleh pembuatnya.

Deeplearning4j merupakan framework yang mampu melakukan proses secara pada lingkungan sistem yang terdistribusi, kemampuan multi-thread maupun single-thread. Ketika melakukan proses training pada lingkungan cluster, dimana proses komputasi dilakukan untuk data besar mampu dilakukan secara lebih cepat. Proses training dilakukan secara paralel dengan mengurangi iterasi dan memiliki kompatibilitas dengan JAVA, SCALA dan CLOJURE. Deeplearning4j berperan sebagai komponen modular dalam komponen yang terbuka sehingga menjadi framework pertama yang mengadaptasi arsitektur micro-service.



Gambar 2.9: Mind map penelitian terdahulu terkait CNN

2.8 Web Service

Teknologi Web Service adalah teknologi yang mengadopsi SOA (Software Oriented Architecture). Pada web service, user mengirimkan request kepada web service

dan web service akan memberikan respon terkait request user tersebut. Agar user bisa berkomunikasi dengan web service, digunakan standard komunikasi yang biasa disebut WSDL (Web Service Description Language). WSDL membentuk spesifikasi dasar komunikasi dari suatu web service dengan:

1. Penyedia service mendeskripsikan fungsi menggunakan WSDL. Definisi tersebut dipublikasi pada repositori layanan. Repositori bisa menggunakan UDDI. Bentuk lain dari direktori juga bisa digunakan.
2. User dari layanan melakukan request kepada repositori untuk menemukan service dan memberikan aturan bagaimana berkomunikasi dengan service tersebut. Bagian dari WSDL yang disediakan oleh penyedia diberikan kepada user. Hal ini akan memberikan informasi kepada user bagaimana bentuk request dan hasil respon yang akan diberikan oleh service.
3. User menggunakan WSDL untuk mengirimkan request kepada penyedia service
4. Penyedia service menyediakan respon kepada user

Android merupakan sistem operasi untuk teknologi mobile yang sudah digunakan secara umum. Penggunaan smartphone berbasis android sudah bukan lagi menjadi barang baru karena kemajuan teknologi sehingga menjadikan harga smartphone menjadi terjangkau dan dapat menjangkau semua elemen masyarakat.

2.9 Batik

Indonesia merupakan negara kepulauan yang memiliki banyak suku dan ras dan sehingga memiliki keanekaragaman bahasa, budaya dan kebiasaan. Salah satu keunikan yang dimiliki Indonesia adalah memiliki keanekaragaman jenis kain yang berasal dari tiap daerah, diantaranya batik, tok wie, kain dodot, kain panjang dll.



Gambar 2.10: Contoh kain dari berbagai daerah di Indonesia

Salah satu kain tradisional Indonesia adalah batik. Batik merupakan kain bergambar yang memiliki gaya, warna dan tekstur dimana proses pembuatannya dilakukan secara manual maupun menggunakan mesin. Batik memiliki beberapa motif seperti motif kawung, motif parangkusumo, motif truntum, motif tambal, motif pamiluto, motif parang, motif liris maupun motif udan nitik.

BAB 3

PERANCANGAN

Metode yang digunakan dalam penelitian ini adalah metode kuantitatif dengan melakukan pengukuran akurasi dari pengujian data tes terhadap model yang terbentuk.

3.1 Teknik Pengumpulan Data

Sebelum melakukan penelitian, terlebih dahulu dilakukan proses pengumpulan data. Teknik yang digunakan untuk melakukan pengumpulan data adalah sebagai berikut:

1. Studi literatur.

Sebelum mengumpulkan data, dilakukan proses studi literatur untuk menemukan jenis data yang tepat untuk melakukan penelitian ini.

2. Pengambilan data.

Proses pengambilan data dilakukan dengan mencari menggunakan teknologi internet dan search engine, misalnya dengan keyword batik, batik Indonesia, dll. Selain itu, dilakukan pengumpulan data secara langsung ke museum tekstil di Jakarta.

3.2 Data

Data yang digunakan dalam penelitian ini merupakan data primer yang diambil berdasarkan kata kunci di internet maupun pengambilan secara langsung seperti yang telah dijelaskan pada butir 3.1. Dalam penelitian ini, terdapat dua jenis data, yaitu data latih dan data uji.

Data latih yang diperlukan adalah kumpulan data batik yang memiliki variasi motif yang berasal dari berbagai daerah di Indonesia.

3.3 Rancangan Penelitian

Penelitian ini dilakukan di Fasilkom UI dengan metode penelitian kuantitatif yaitu dengan mengukur ketepatan prediksi asal daerah batik dari motif kain. Metode

yang digunakan untuk membuat model prediksi motif kain adalah CNN dimana input akan dipecah menjadi ukuran yang lebih kecil dan diproses kedalam beberapa layer sehingga akan ditemukan fitur dari gambar yang kemudian menghasilkan model untuk melakukan deteksi asal daerah batik dari pola kain.

Alur kegiatan yang dilakukan dalam penelitian ini terdiri dari langkah, yaitu identifikasi masalah, studi literatur, pengumpulan data, Implementasi CNN, Implementasi Web Service, Implementasi Web Service Client, Latih CNN, Uji CNN, Analisis hasil, Penarikan kesimpulan dan pembuatan laporan. Langkah-langkah tersebut dapat digambarkan dalam alur proses yang dapat dilihat pada gambar 3.1. Adapun target durasi waktu kerja dari langkah-langkah pada alur yang digambarkan pada tabel 3.2 dapat dilihat pada table project plan sebagai berikut.

Tabel 3.1: Project plan penelitian pengenalan batik dengan android

No	Deskripsi
1	Identifikasi Masalah
2	Studi Literatur
3	Pengumpulan Data
4	Implementasi CNN
5	Implementasi Web Service
6	Implementasi Web Service Client
7	Pelatihan CNN
8	Pengujian CNN
9	Analisis Hasil
10	Penarikan Kesimpulan
11	Pembuatan Laporan

Tabel 3.2: Timeline penelitian pengenalan batik dengan android

No	Deskripsi	Jul	Aug	Sep	Oct	Nov	Dec
1	Identifikasi Masalah	x					
2	Studi Literatur	x					
3	Pengumpulan Data		x				
4	Implementasi CNN		x	x	x		
5	Implementasi Web Service		x	x	x		
6	Implementasi Web Service Client		x	x	x		
7	Pelatihan CNN		x	x	x		
8	Pengujian CNN		x	x	x		
9	Analisis Hasil					x	
10	Penarikan Kesimpulan					x	
11	Pembuatan Laporan						x

Pengambilan data dilakukan pada bulan Maret 2016 pada museum tekstil jakarta, sedangkan pengambilan data via internet, dilakukan dari awal januari 2016 hingga saat ini.


3.4 Pelatihan Model CNN

Pelatihan motif kain dimulai dari input gambar yang sudah diberikan label secara manual berdasarkan kata kunci pencarian pada internet berdasarkan daerah asal batik dan data yang disediakan oleh museum tekstil. Gambar akan dijadikan input pada deeplearning4j dengan inisialisasi parameter:

- Seed
- Iterations
- Regularizations
- L2
- Learning rate
- Weightinit
- Optimization Algorithm
- Updater


Setelah melakukan inialisasi parameter, data gambar akan diproses kedalam layer dengan urutan sbb:

- Layer 0 : Convolution Layer
- Layer 1 : Subsampling Layer Max Pooling
- Layer 2 : Convolution Layer
- Layer 3 : Subsampling Layer Max Pooling
- Layer 4 : Dense Layer
- Layer 5 : Output Layer



Gambar 3.1: Arsitektur CNN

Hasil dari output layer akan melakukan evaluasi terhadap data testing dan dilakukan pengukuran nilai . model hasil pembelajaran deeplearning4j akan disimpan dalam bentuk file biner sehingga bisa digunakan kembali untuk melakukan deteksi daerah asal kain batik.



Gambar 3.2: Arsitektur Server untuk CNN

DAFTAR REFERENSI

- [1] izhang Xia, Bailing Zhang, Frans Coenen. Face Occlusion Detection Based on Multi-task Convolution Neural Network. 2015 12th International Conference on Fuzzy Systems and Knowledge Discovery (FSKD)
- [2] arnest Paul Ijjina, C Krishna Mohan. Human Action Recognition based on Motion Capture Information using Fuzzy Convolution Neural Networks.
- [3] sien-I Lin, Ming-Hsiang Hsu, and Wei-Kai Chen. Human Hand Gesture Recognition Using a Convolution Neural Network. 2014 IEEE International Conference on Automation Science and Engineering (CASE) Taipei, Taiwan, August 18-22, 2014
- [4] izhang Xia, Bailing Zhang, Frans Coenen. Face Occlusion Detection Based on Multi-task Convolution Neural Network. 2015 12th International Conference on Fuzzy Systems and Knowledge Discovery (FSKD)
- [5] arnest Paul Ijjina, C Krishna Mohan. Human Action Recognition based on Motion Capture Information using Fuzzy Convolution Neural Networks.
- [6] sien-I Lin, Ming-Hsiang Hsu, and Wei-Kai Chen. Human Hand Gesture Recognition Using a Convolution Neural Network. 2014 IEEE International Conference on Automation Science and Engineering (CASE) Taipei, Taiwan, August 18-22, 2014
- [7] anik Suciati, Agri Kridanto, Mohammad Farid Naufal, Muhammad Machmud & Ardian Yusuf Wicaksono. Fast Discrete Curvelet Transform And HSV Color Features For Batik Image Classification. 2015 International Conference on Information, Communication Technology and System (ICTS)
- [8] inyan Yu1, Guohao Lyu, Siwei Luo, Junbo Liu. A Convolution Neural Network Based Variational Restoration Model
- [9] anik Suciati, Agri Kridanto, Mohammad Farid Naufal, Muhammad Machmud & Ardian Yusuf Wicaksono. Fast Discrete Curvelet Transform And HSV Color Features For Batik Image Classification. 2015 International Conference on Information, Communication Technology and System (ICTS)

- [10] . M. Rasdi Rere, Mohamad Ivan Fanany, Aniati Murni Ary-murthy. Metaheuristic Algorithms for Convolution Neural Network. Hindawi Publishing Corporation Computational Intelligence and Neuroscience
- [11] ejun Tang, Liangrui Peng, Qian Xu, Yanwei Wang dan Akio Furuhashi. CNN based Transfer Learning for Historical Chinese Character Recognition. 2016 12th IAPR Workshop on Document Analysis Systems